

# Eats

Данные содержат 18 58 328 уникальных номеров телефонов с именем клиента (20 символов в среднем)

Определимся с форматом записи номера телефона, пусть номера записаны в таком виде:

**7XXXXXXXXXX**, то есть 11 символов на один номер телефона (к такому формату всегда можно заранее преобразовать базу)

## В каком формате хранить номера?

1. В виде строки

Для выбранного формата записи телефонного номера получим 11 байт на номер или  $11 * 18\,58328 = 206,3\text{mb}$

2. В виде 64 битного числа

Для числа 79 999 999 999 потребуется 37 бит = 4,652 байт

Например, в формате long (Java), получим 8 байт на 1 номер телефона или 150,1mb на всю базу номеров

## Сколько занимают имена?

Исходя из условия, получим в среднем 20 байт на имя пользователя, то есть  $18\,58328 * 20 = 375.2\text{mb}$

## Средний размер всех пар (телефон: имя)

Если номера телефонов хранятся в строках, тогда предполагаемый объем данных будет равен  $581.5\text{MB}$

Если же в формате числа -  $525.3\text{MB}$

В базах данных телефонные номера обычно хранятся в строковых форматах данных, поэтому пока остановимся на варианте с 581.5mb, будем работать со строками

## Реализация поиска за постоянное время

Для решения данной задачи будем использовать хеш таблицу, ключи - хеши от номеров телефона, в узлах лежат пары (номер : имя)

В качестве хэш функции возьмем  $hash(string) = abs(hashCode(string)) \% tableSize$ , где hashCode - стандартная операция хеширования в Java.

Размер таблицы возьмем равным 18 758 329 - простое число для более эффективного распределения по "ячейкам" таблицы, в качестве самой таблицы используем массив `LinkedList[tableSize]`. Вставка будет осуществляться следующим образом:

```
if (table[h] == null) {  
    table[h] = new LinkedList<Data>()  
}  
table[h].add(Data)
```

Размер одного узла `LinkedList` 24 байта, если выбранная хеш функция достаточно хорошая, чтобы равномерно распределить значения по ячейкам, тогда самое наибольшее, что можно получить, это 18 758 328 объектов `LinkedList` + 1 неиспользованный указатель (ссылка), размер которой 4 байта, то есть в сумме -  $18758328 * 24 + 4 = 450.2MB$

## Корректирование первоначальных размеров данных

Размер 1 символа в Java = 2 байта, поэтому подсчитанный размер базы данных нужно умножить на 2, более того, размер объекта `String` на 64битных системах помимо самого размера массива символов = 16 байт, то есть только данные будут занимать:  $18758328 * (20 + 11 + 16) * 2 = 1.763GB$

Таким образом, все вместе, то есть сама таблица + данные будут занимать около  $2.213GB$

## Оптимизация потребляемой памяти

Первое, что можно оптимизировать, это объем памяти, потребляемый самой таблицей. Вместо `LinkedList` можно использовать `ArrayList`, который будет потреблять 4 байта на элемент вместо 24, то есть суммарно таблицу можно уместить в  $75.03MB$  вместо  $450.2MB$

Далее вместо класса `String` можно использовать более легковесный вариант - массив примитивов `char[]`, с явным указанием байта - символа конца строки, в таком случае размер имени в среднем станет равным 21, а номер телефона 12 символов. тогда общий размер станет равен

$(21 + 12) * 2 * 18758328 = 1.238GB$  вместо  $1.763GB$

Минимизировав, получаем  $1.238GB + 75.03MB = 1.313GB$